

Научная статья

DOI: 10.15593/2224-9397/2025.4.07

УДК 519.237.5

Н.В. Андриевская¹, С.В. Остапенко², А.А. Южаков¹¹Пермский национальный исследовательский политехнический университет, Пермь, Российская Федерация²АО «ОДК-СТАР», Пермь, Российская Федерация

ПРИМЕНЕНИЕ НЕЙРОННЫХ СЕТЕЙ В ЭКСПЕРИМЕНТАЛЬНЫХ МОДЕЛЯХ ДЛЯ ЗАДАЧИ ПОВЫШЕНИЯ ОТКАЗОУСТОЙЧИВОСТИ ГАЗОТУРБИННЫХ ДВИГАТЕЛЕЙ

Системы управления современными летательными аппаратами, а также непосредственно авиационный двигатель должны отличаться высокой степенью надежности. Поэтому особое внимание при проектировании и функционировании систем управления газотурбинными двигателями уделяется вопросам повышения отказоустойчивости и надежности как самого двигателя, так и измерительных каналов. В процессе функционирования газотурбинного двигателя возможны ситуации такие, как отказ отдельных датчиков в измерительных каналах, представление недостоверной информации датчиками. Нейро-се Центральной задачей в таком подходе является построение экспериментальной модели. В данной статье рассматриваются нейросетевые экспериментальные модели. **Целью работы** является расчет идентификационной модели на базе нейронных сетей. Для этого выбрана модель параметров газотурбинного двигателя, в которой каждый параметр представляет собой функциональную зависимость от других. В качестве функционального оператора рассматривается нейронная сеть. В статье приводятся результаты обучения нейросетевых моделей, оценивается их адекватность. **Результатом** выполненных исследований является выбор наилучшей модели. **Методами исследования** являются методы структурной и параметрической идентификации, методы обучения нейронных сетей, статистический анализ адекватности моделей. **Практическая значимость** определяется применением экспериментальной модели в качестве «третьего» голоса в оценивании неисправности (отказов) как отдельных датчиков измерительного канала, так и всего канала в целом, что в конечном итоге приводит не только к надежному функционированию авиационного двигателя, но и эффективному управлению им.

Ключевые слова: газотурбинный двигатель, отказоустойчивость, измерительный канал, экспериментальная модель, нейронные сети, обучение нейронных сетей, адекватность моделей.

N.V. Andrievskaia¹, S.V. Ostapenko², A.A. Iuzhakov¹

¹Perm National Research Polytechnic University,
Perm, Russian Federation

²JSC "ODK-STAR", Perm, Russian Federation

APPLICATION OF NEURAL NETWORKS IN EXPERIMENTAL MODELS TO IMPROVE FAILURE RESISTANCE OF GAS TURBINE ENGINES

The control systems of modern aircraft, as well as the aircraft engine itself, must be highly reliable. Therefore, special attention is paid to improving the fault tolerance of both the engine and the measurement channels during the design and operation of gas turbine engine control systems. During the operation of a gas turbine engine, the following situations may occur: failure of individual sensors in the measurement channels, and inaccurate information provided by the sensors. To solve this problem, an approach is proposed in which, in flight conditions, the parameters of the embedded mathematical model are refined using an identification approach, and the failure of the measurement channels is diagnosed in comparison with this model. The central task in this approach is to build an experimental model. This article discusses neural network experimental models. **The purpose** of the work is to calculate an identification model based on neural networks. To do this, a model of gas turbine engine parameters is selected, in which each parameter is a functional dependence on the others. A neural network is considered as a functional operator. The article presents the results of training neural network models and evaluates the adequacy of the models. **The research results** in the selection of the best model. **Research methods** are methods of structural and parametric identification, methods of training neural networks, statistical analysis of model adequacy. **Practical significance** is determined by the application of the experimental model as a "third-party" voice in assessing the malfunction (failures) both individual sensors of the measurement channel and the entire channel as a whole, which ultimately leads not only to the reliable functioning of the aircraft engine, but also to its effective control.

Keywords: gas turbine engine, fault tolerance, measurement channel, experimental model, neural networks, neural network training, model adequacy

Введение

Проектирование и функционирование летательных аппаратов в первую очередь должны обеспечивать надежность функционирования всех подсистем газотурбинного двигателя (ГТД) [1–3]. Данная задача обеспечивается как точностью проектирования систем управления двигателя, так и обеспечением отказоустойчивости как двигателя в целом, так и систем управления ГТД, включая измерительные каналы, элементы резервной автоматики и прочее [4–5]. Повышение отказоустойчивости обеспечивается за счет аппаратурно-временной (структурной, информационной или алгоритмической) избыточности элементов систем автоматического управления (САУ) газотурбинными двигателями (ГТД) [6–7].

Структурная избыточность создается за счет введения дублирующих каналов измерения основных параметров газотурбинного двигателя [7–8]. Тогда возникает проблема определения, какой канал предоставляет достоверную информацию [7–9].

В качестве эталона для подтверждения достоверности может выступить встроенная математическая модель [7]. Однако следует учитывать стохастичность, нестационарность ГТД и зависимость от внешних условий [2, 8–9]. Поэтому в качестве уточнения математической модели предлагается использовать экспериментальную, построенную на данных полного цикла полета в реальных условиях с привнесением методов машинного обучения.

При построении экспериментальных моделей возможно использование различных классов моделей [8–10]. Авторами в [11] подробно рассмотрены регрессионные модели. В данной статье предлагается рассмотреть идентификацию параметров ГТД с помощью нейронных сетей [11–13].

Основная цель работы – построение экспериментальной модели параметров ГТД для использования в качестве дополнительного («третьего») канала знаний о векторе состояния объекта управления. Сопоставление значений параметров экспериментальной модели с реальными значениями датчиков измерительного канала позволяет делать вывод об отказах в каналах измерения.

Объект исследования – экспериментальная модель параметров ГТД (на примере двигателя ПД-14). Предмет исследования – методы идентификации моделей на базе нейронных сетей [12–16].

Задачи исследования:

- 1) провести анализ адекватности нейросетевых моделей как на обучающей, так и на тестовой выборке;
- 2) осуществить выбор наилучшей нейросетевой модели;
- 3) определить точности регрессионных и нейросетевых моделей [10–11].

1. Математические модели параметров ГТД

В качестве основных параметров ГТД рассмотрены следующие: $T_{ВХ}$ – температура газов за турбиной; $P_{ВХ}$ – давление газов за турбиной; P_K – давление воздуха за компрессором; G_T – расход топлива; $h_{ПС}$ – по-

ложение гидроцилиндра промежуточной ступени; $h_{\text{ВНА}}$ – положение гидроцилиндра входных направляющих аппаратов; N_2 – частота вращения ротора компрессора; N_1 – частота вращения ротора вентилятора; $A_{\text{РУД}}$ – положение рычага управления двигателем) [10–11]. Тепловая карта взаимных зависимостей данных параметров, полученная методами структурной идентификации, приведена на рис. 1 [10–11].




Рис. 1. Тепловая таблица взаимных зависимостей исследуемых параметров ГТД

Таким образом, экспериментальная математическая модель параметров ГТД может быть представлена в виде:

$$\begin{cases} T_{\text{BX}} = f_1(P_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_2, N_1, A_{\text{РУД}}), \\ P_{\text{BX}} = f_2(T_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_2, N_1, A_{\text{РУД}}), \\ P_{\text{К}} = f_3(T_{\text{BX}}, P_{\text{BX}}, G_{\text{Т}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_2, N_1, A_{\text{РУД}}), \\ G_{\text{Т}} = f_4(T_{\text{BX}}, P_{\text{BX}}, P_{\text{К}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_2, N_1, A_{\text{РУД}}), \\ h_{\text{ПС}} = f_5(T_{\text{BX}}, P_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ВНА}}, N_2, N_1, A_{\text{РУД}}), \\ h_{\text{ВНА}} = f_6(T_{\text{BX}}, P_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ПС}}, N_2, N_1, A_{\text{РУД}}), \\ N_2 = f_7(T_{\text{BX}}, P_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_1, A_{\text{РУД}}), \\ N_1 = f_8(T_{\text{BX}}, P_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_2, A_{\text{РУД}}), \\ A_{\text{РУД}} = f_9(T_{\text{BX}}, P_{\text{BX}}, P_{\text{К}}, G_{\text{Т}}, h_{\text{ПС}}, h_{\text{ВНА}}, N_2, N_1). \end{cases} \quad (1)$$

Оценивание модели проводится с помощью нейронных сетей.

Адекватность моделей оценивается по предлагаемой целевой функции [10–11]:

$$J_{\text{обуч}} = 0,6(1 - R^2) + 0,2\text{MAE} + 0,2\text{RMSE}, \quad (2)$$

где R^2 – коэффициент детерминации параметра; MAE – средняя абсолютная ошибка; RMSE – корень из среднеквадратичной ошибки.

Очевидно, что наилучшая модель соответствует наименьшему значению целевой функции $J_{\text{обуч}}$. Для обеспечения надежности в определении отказов датчиков основных параметров нейросетевые модели должны обеспечивать численные значения целевой функции не более 0,01.

2. Выборка для обучения нейронных сетей

В качестве исходных данных для обучения нейронной сети были использованы результаты испытаний двигателя ПД-14 в полете самолёта МС-21 Москва–Дубай и обратно. Обучение и верификация осуществлялись на данных полета Москва–Дубай. Тестирование моделей осуществлялось на данных обратного полета (Дубай–Москва). Полная выборка прямого полета представляет собой набор технологических точек [0, 30000]. Обучение сети осуществляется на выборке [0, 15000]. Верификация модели на выборке [15000, 30000].

Оценка адекватности построенных моделей осуществляется тестированием на обратном полете [0, 40000]. Следует отметить, что авторами были рассмотрены регрессионные модели параметров ГТД на данной выборке [11].

Данная статья является продолжением работы в поисках наилучшей модели параметров. Предобработка данных включает в себя процедуру нормирования по принципу mini-max [17]:

$$\hat{x}_i = (x_i - x_{i_min}) / (x_{i_max} - x_{i_min}). \quad (3)$$

Вектор исходных данных расширен за счет дополнительных входов – «признаков», которые представляют собой разницы между основными входными данными, например (например, $\Delta P_{\text{руд}} - \Delta P_1$), переменных, отражающих физические взаимосвязи параметров (например, $\Delta P_{\text{к}} \times \Delta P_{\text{вн}}$ отражает физическую переменную «количество воздуха

в ГТД), а также динамические переменные, характеризующие скорость изменения параметров.

Таким образом, полноразмерная входная выборка представляет собой матрицу 97 на 30000, где 97 – это общее количество входных параметров [11].

3. Выбор структуры нейронной сети

Несмотря на многообразие структур нейронных сетей, для задач проектирования интеллектуальных систем управления и контроля авиационных двигателей на практике применяется ограниченный класс нейросетевых моделей [18, 19]. Это обусловлено повышенными требованиями к надежности моделей, к объему памяти и скорости как обучения, верификации, так и использованию моделей на базе нейронных сетей. С учетом данных требований были выбраны следующие нейронные сети: автоэнкодер и рекуррентные сети [20–23].

Данный выбор обусловлен особенностями модели: достаточно большой выборкой обучения, требованиями по минимизации времени расчета, относительно несложной структурой (1–2 слоя), простотой обучения [19–23]. Обучение, верификация и тестирование моделей реализованы на языке Python [24–25].




Рис. 2. Структура автоэнкодера

Автоэнкодер был выбран по следующим причинам:

- базовая модель машинного обучения;
- простота использования – модель нейронной сети с обучением без учителя;
- эффективная работа с большим массивом данных за счет сжатия, кодирования и восстановления данных;
- использование всего одного скрытого слоя.

Структура автоэнкодера представлена на рис. 2.

На рис. 2 представлены входные данные – Input, сжатие и кодирование данных – Encode, скрытый слой – Hidden, декодирование и восстановление данных – Decode, выходной слой – выходные данные – Out.

Также для построения нейросетевой модели была выбрана структура сверточных сетей.

Сверточная нейронная сеть – это однонаправленная нейронная сеть, для обучения которой используются стандартные методы, чаще всего метод обратного распространения ошибки (рекуррентные сети). Сети на основе свёрточных нейронных сетей являются стандартом в подходах к глубокому обучению [20, 21, 23].

Сверточная сеть представлена на рис. 3.




Рис. 3. Сверточная сеть прогнозирования параметров

Принцип работы сверточной сети заключается также в сжатии информации для эффективного расчета весовых коэффициентов нейронной сети.

В качестве оценки отдельного параметра в сверточной сети используется модель рекуррентной нейронной сети с обратным распределением ошибки (рис. 4).




Рис. 4. Рекуррентная сеть одного параметра

Результаты обучения модели автоэнкодер приведены в табл. 1. При обучении было использовано 29 входных сигналов (основные сигналы и дополнительные признаки, в основном разности основных параметров двигателя)

Таблица 1

Результаты моделирования нейронной сети
автоэнкодер параметров ГТД (29 входных данных)

Параметр	MAPE	RMSE	R^2	MAE	$J_{обуч}$
T_{BX}	3,998559	0,001405	-0,494297	0,021759	0,901211
P_K	3,973069	0,000338	0,984923	0,010146	0,011143
G_T	8,950017	0,000355	0,986556	0,007037	0,009545
$h_{ПС}$	9,831227	0,000288	0,996260	0,010820	0,004466
$h_{ВНА}$	1,330388	0,000031	0,999023	0,004408	0,001474
N_2	1,933129	0,001213	0,817116	0,011901	0,112354
N_1	7,184387	0,003628	0,872712	0,029134	0,082925
$A_{руд}$	116,444691	0,001748	0,889905	0,019487	0,070304

По интегральному критерию наилучшие результаты оценивания по нейросетевой модели автоэнкодера были получены по параметрам: $h_{ПС}$, $h_{ВНА}$, G_T .

Результаты обучения модели автоэнкодера для полноразмерного входного вектора (97 входов) приведены в табл. 2.

Таблица 2

Результаты моделирования нейронной сети
автоэнкодера параметров ГТД (97 входных данных)

Параметр	MAPE	RMSE	R^2	MAE	$J_{обуч}$
$T_{ВХ}$	4,524056	0,000878	0,065937	0,022995	0,565212
P_K	10,498962	0,003247	0,855131	0,054960	0,098563
G_T	13,180852	0,004633	0,824739	0,065931	0,119269
$h_{ПС}$	13,922615	0,002966	0,961546	0,025755	0,028817
$h_{ВНА}$	8,019438	0,001386	0,956730	0,031061	0,032451
N_2	aN2	0,876333	0,000185	0,972081	0,006017
N_1	3,517520	0,000708	0,975165	0,020367	0,019116
$A_{руд}$	11,592857	0,001111	0,929999	0,014558	0,045135

Модель автоэнкодера с расширенным входом дала удовлетворительные результаты для N_2 . В табл. 3 приведены результаты оценки адекватности модели для сверточной сети.

Таблица 3

Результаты моделирования сверточной нейронной сети

Параметр	MAPE	RMSE	R^2	MAE	$J_{обуч}$
$T_{ВХ}$	3,008886	0,000621	0,339000	0,015698	0,399864
P_K	20,563649	0,014913	0,334483	0,119077	0,426108
G_T	18,577373	0,013904	0,473819	0,111327	0,340755
$h_{ПС}$	15,752114	0,001274	0,983469	0,011552	0,012484
$h_{ВНА}$	5,714946	0,001154	0,963970	0,025338	0,026917
N_2	1,013666	0,000166	0,975036	0,007649	0,016541
N_1	1,949418	0,000448	0,984267	0,011020	0,011733
$A_{руд}$	69,265675	0,000755	0,952429	0,012292	0,031152

Как показали исследования, сверточные модели не дали удовлетворительного результата. Для повышения точности моделей были проведены дополнительные исследования, связанные с изменением гиперпараметров нейронной сети [20, 21, 23, 24]. Однако существенно точность моделей не изменилась.

Таким образом, можно сделать вывод, что удовлетворительные результаты нейросетевые модели дали для параметров $h_{ВНА}$, $h_{ПС}$, G_T , N_2 . Однако для других параметров ($T_{ВХ}$, P_K , N_1 , $A_{руд}$) они не обеспечили заданный уровень целевой функции. Кроме того, при повторном обучении проявился эффект «переобучения» нейронной сети, что отразилось на резком возрастании всех показателей адекватности модели (MAPE, RMSE, MAE

и $(1-R^2)$. Повысить качество моделей возможно за счет выбора других структур нейронных сетей, но это приведет к увеличению времени обучения, верификации, объему памяти. Тестирование нейронных моделей осуществлялось на данных обратного полета Дубай–Москва. Наилучшие результаты показали модели $h_{ВНА}$, $h_{ПС}$. На рис. 5–7 представлены результаты моделирования параметра $h_{ПС}$ на второй половине полета




Рис. 5. Результаты моделирования параметра $h_{ПС}$ (actual – исходные данные, predict – выходы модели нейронной сети «автоэнкодер») и график абсолютной ошибки MAE




Рис. 6. Результаты моделирования параметра $h_{ПС}$ (actual – исходные данные, predict – выходы модели нейронной сети «автоэнкодер с расширенным вектором входных данных») и график абсолютной ошибки MAE




Рис. 7. Результаты моделирования параметра $h_{ПС}$ (actual – исходные данные, predict – выходы модели сверточной нейронной) и график абсолютной ошибки MAE

С учетом исследований регрессионных моделей [11] можно привести сводную таблицу регрессионных и нейросетевых моделей параметров ГТД (табл. 4).

Таблица 4

Результаты моделирования параметров на базе
регрессионной и нейросетевой моделей

Параметр	Вид модели	MAPE	RMSE	R^2	MAE	$J_{обуч}$
$T_{ВХ}$	Регрессионная модель Linear Regression	3,011174	0,000357	0,619819	0,015508	0,231282
P_K	Регрессионная модель Gradient Boosting Regressor	2,508505	0,000113	0,994951	0,008332	0,004718
G_T	Регрессионная модель Linear Regression	1,327289	0,000046	0,998253	0,005513	0,002160
$h_{ПС}$	Нейронная сеть Simple_dense_autoencoder	9,831227	0,000288	0,996260	0,010820	0,004466

Окончание табл. 4

Параметр	Вид модели	MAPE	RMSE	R^2	MAE	$J_{обуч}$
$h_{ВНА}$	Нейронная сеть Simple_dense_autoencoder	1,330388	0,000031	0,999023	0,004408	0,001474
N_2	Регрессионная модель Random Forest Regressor	0,104315	0,000002	0,999665	0,000810	0,000363
N_1	Регрессионная модель Linear Regression	0,727167	0,000041	0,998555	0,004924	0,001860
$A_{руд}$	Регрессионная модель SGDRegressor	18,018245	0,000484	0,969520	0,007979	0,019980

Для параметров $h_{ПС}$, $h_{ВНА}$ проведен анализ регрессионных и нейросетевых моделей (табл. 5) [11].

Таблица 5

Результаты моделирования параметров $h_{ПС}$ и $h_{ВНА}$
на базе регрессионной и нейросетевой моделей

Параметр	Вид модели	MAPE	RMSE	R^2	MAE	$J_{обуч}$
$h_{ПС}$	Нейронная сеть Simple_dense_autoencoder	9,831227	0,000288	0,996260	0,010820	0,004466
$h_{ПС}$	Random Forest Regressor Grid Rand Search	24,920048	0,000055	0,997577	0,003151	0,002095
$h_{ВНА}$	Нейронная сеть Simple_dense_autoencoder	1,330388	0,000031	0,999023	0,004408	0,001474
$h_{ВНА}$	Random Forest Regressor Grid Rand Search	1,688765	0,000039	0,999255	0,004062	0,001267

Анализ результатов показал, что обе модели характеризуются интегральным показателем качества, меньшим допустимого показателя 0,01. Но регрессионные модели дают лучший результат:

$$\begin{aligned} h_{\text{ПСрег}} &= 0,002095 < h_{\text{ПСинс}} = 0,004466 < 0,01, \\ h_{\text{ВНАрег}} &= 0,001267 < h_{\text{ВНАинс}} = 0,001474 < 0,01. \end{aligned} \quad (4)$$

Таким образом, можно сделать вывод, что с точки зрения унификации экспериментальных моделей предпочтительнее регрессионные модели.

Особое внимание следует уделить оцениванию параметра $T_{\text{ВХ}}$, так как и регрессионные, и нейросетевые модели не позволяют его оценить с заданной точностью

Заключение

В работе проведено исследование экспериментальных моделей основных параметров ГТД. В качестве класса моделей были предложены нейронные сети; автоэнкодер, автоэнкодер для расширенного вектора данных, сверточные сети. Были проведены дополнительные исследования – изменения гиперпараметров нейронных сетей. Анализ результатов проводился на основе ошибок MAPE, RMSE, MAE и коэффициента детерминации. Полноразмерный анализ адекватности моделей показал, что удовлетворительные результаты нейросетевые модели дают для параметров $h_{\text{ВНА}}$ и $h_{\text{ПС}}$. В статье приведен сравнительный анализ регрессионных и нейросетевых моделей.

Осуществлен выбор наилучшего класса моделей. Показаны перспективы дальнейших исследований в решении задачи повышения отказоустойчивости газотурбинных двигателей за счет применения экспериментальных моделей: в режиме полета экспериментальная модель формирует вектор параметров ГТД, который сравнивается с показаниями измерительных каналов. В случае несовпадения численных параметров векторов идентифицируются как отдельные датчики параметров ГТД, так и измерительный канал в целом. Исследования проводились на современном и перспективном двигателе ПД-14.

Работа имеет очевидную практическую значимость с точки зрения повышения надежности авиационных двигателей летательных аппаратов.

Библиографический список

1. Иноземцев, А.А. Газотурбинные двигатели / А.А. Иноземцев, В.Л. Сандрацкий. – Пермь: Изд-во ОАО «Авиадвигатель», 2006. – 1204 с.
2. Проблемы управления сложными динамическими объектами авиационной и космической техники / под ред. С.Н. Васильева. – М.: Машиностроение, 2015. – 519 с.
3. Гуревич, О.С. Анализ современных САУ ТРДД и направления их развития / О.С. Гуревич, А.И. Гулиенко, С.А. Сметанин // Системы автоматического управления авиационными силовыми установками: сб. науч. тр. / под ред. О.С. Гуревича. – М., 2020. – С. 7–12.
4. Интеллектуальные системы управления и контроля газотурбинных двигателей / С.Н. Васильев [и др.]; под ред. С.Н. Васильева. – М.: Машиностроение, 2008. – 549 с.
5. Garg, S. Aircraft turbine engine control research at NASA Glenn Research Center / S. Garg // Journal of Aerospace Engineering. – 2013. – Vol. 26, iss. 2. – P. 422–438.
6. Gurevich, O. Automatic control to reduce the effect of deterioration of gas turbine engine components on its performance characteristics / O. Gurevich, S. Smetanin, M. Trifonov // AIAA Propulsion and Energy 2021 Forum, virtual conference, August 9–11, 2021. – 11 p.
7. Гольберг, Ф.Д. Математическая модель двигателя в САУ ГТД для повышения надежности и качества управления / Ф.Д. Гольберг, О.С. Гуревич, А.А. Петухов // Труды МАИ. – 2012. – Т 58. – С. 16–24.
8. Гольберг, Ф.Д. Идентификация бортовой математической модели двигателя / Ф.Д. Гольберг, А.А. Петухов // Системы автоматического управления авиационными силовыми установками: сб. науч. трудов. – М., 2020. – С. 61–65.
9. Остапенко, С.В. Повышение отказоустойчивости САУ с помощью применения алгоритмов искусственного интеллекта / С.В. Остапенко, А.А. Южаков // Математическое моделирование: материалы II Междунар. конф. – М., 2021. – С. 68–70.
10. Остапенко, С.В. Повышение отказоустойчивости газотурбинных двигателей за счёт использования встраиваемой экспериментальной модели / С.В. Остапенко, Н.В. Андриевская, А.А. Южаков // Научно-технический вестник Поволжья. – 2023. – № 11. – С. 372–378.

11. Остапенко, С.В. Применение регрессионных моделей в задачах повышения отказоустойчивости газотурбинных двигателей / С.В. Остапенко, Н.В. Андриевская, А.А. Южаков // Вестник Поволж. гос. технолог. ун-та. Сер. Радиотехнические и инфокоммуникационные системы. – 2024. – № 1 (61). – С. 70–76.
12. Эзрохи, Ю.А. Идентификация математической модели авиационного ГТД по результатам испытаний / Ю.А. Эзрохи, С.М. Каленский // Труды МАИ. – 2022. – № 122. – С. 19–38.
13. Андриевская, Н.В. Идентификация нелинейной модели с использованием моделей нечеткой логики и искусственных нейронных сетей / Н.В. Андриевская // Нейрокомпьютеры: разработка, применение. – 2017. – № 6. – С. 3–8.
14. Andrievskaya, N.V. Identification of parametres of nonlinear model of a hydro-mechanical system / N.V. Andrievskaya, N.R. Mubarakzyanov, I.I. Bezukladnikov // Proceedings of the 19th International Conference on Soft Computing and Measurements, SCM-2016. – 2016. – P. 145–158.
15. Васильев, В.И. Нейросетевые технологии проектирования систем управления авиадвигателем / В.И. Васильев, И.И. Идрисов, А.С. Макаров // Инновационные информационные технологии: тр. российско-немецкого сем. – Уфа, 2009. – С. 72–77.
16. Васильев, В.И. Проектирование перспективной нейросетевой системы управления ГТД / В.И. Васильев, И.И. Идрисов, А.С. Макаров // CSIT'2009: тр. 11-го Междунар. сем. по компьют. наукам и информац. технологиям. – Крит, Греция, 2009. – С. 13–18. (Статья на англ. яз.).
17. Ершов, И.А. Использование корректного нормирования статистических данных в кластерном анализе / И.А. Ершов, О.В. Стукач // Современные технологии поддержки принятия решений в экономике: сб. тр. всерос. науч.-практ. конф. студентов, аспирантов и молодых ученых, Юрга, 19–20 ноября 2015 г. – Томск: Изд-во ТПУ, 2015. – С. 32–34.
18. Васильев, В.И. Нейросетевые технологии в задачах управления и контроля авиационных двигателей. / В.И. Васильев, И.И. Идрисов, А.С. Макаров // Системы управления и информационные технологии. – 2011. – № 1.1 (43). – С. 122–126.
19. Проектирование и техническая реализация интеллектуальных систем управления авиационными газотурбинными двигателями / В.И. Васильев, И.И. Идрисов, И.А. Каримов, А.С. Макаров // Интеллектуальные системы управления. – М.: Машиностроение, 2010. – С. 142–153.

20. Дейтел, П. Д27 Python: Искусственный интеллект, большие данные и облачные вычисления / П. Дейтел, Х. Дейтел. – СПб.: Питер, 2020. – 864 с.
21. Andrew NG Machine learning yearning. – URL: <http://www.mlyearning.org/>
22. Weizhong, Y. Toward automatic time-series forecasting using neural networks / Y. Weizhong // IEEE Transaction on neural networks and learning systems. – 2012. – Vol. 23, № 7. – P. 1028–1039.
23. Машинное обучение: основы, алгоритмы и практика применения / Дж. Уатт [и др.]; пер. с англ. – СПб.: БХВ-Петербург, 2022. – 640 с.
24. Шолле, Ф. Глубокое обучение на Python / Ф. Шолле. – СПб.: Питер, 2023. – 576 с.
25. Рашка, С. Python и машинное обучение / С. Рашка, В. Мирджалили. – Киев: Диалектика, 2020. – 848 с.

References

1. Inozemtsev A.A., Sandratskii V.L. Gazoturbinnye dvigateli [Gas-Turbine Engines]. Perm': OAO "Aviadvigatel'", 2006, 1204 p.
2. Problemy upravleniia slozhnymi dinamicheskimi ob"ektami aviatsionnoi i kosmicheskoi tekhniki [Problems of Control of Complex Dynamic Objects of Aviation and Space Engineering]. Ed. S.N. Vasil'ev. Moscow: Mashinostroenie, 2015, 519 p.
3. Gurevich O.S., Gulienko A.I., Smetanin S.A. Analiz sovremennykh SAU TRDD i napravleniia ikh razvitiia [Analysis of Modern TSDDs Automatic Control Systems and Directions of Their Development]. *Sistemy avtomaticheskogo upravleniia aviatsionnymi silovymi ustanovkami. Sbornik nauchnykh trudov*. Ed. O.S. Gurevich. Moscow, 2020, pp. 7-12.
4. Vasil'ev S.N. et al. Intellektual'nye sistemy upravleniia i kontrolya gazoturbinnnykh dvigatelei [Intelligent control and monitoring systems for gas turbine engines]. Ed. S.N. Vasil'ev. Moscow: Mashinostroenie, 2008, 549 p.
5. Garg S. Aircraft turbine engine control research at NASA Glenn Research Center. *Journal of Aerospace Engineering*, 2013, vol. 26, iss. 2, pp. 422-438.
6. Gurevich O., Smetanin S., Trifonov M. Automatic control to reduce the effect of deterioration of gas turbine engine components on its performance characteristics. *AIAA Propulsion and Energy 2021 Forum, virtual conference, August 9-11, 2021*, 11 p.

7. Gol'berg F.D., Gurevich O.S., Petukhov A.A. Matematicheskaya model' dvigatelya v SAU GTD dlia povysheniia nadezhnosti i kachestva upravleniia [Mathematical model of the engine in the GTE ACS for improving the reliability and quality of control]. *Trudy Moskovskogo aviatsionnogo instituta*, 2012, vol. 58, pp. 16-24.

8. Gol'ber F.D., Petukhov A.A. Identifikatsiia bortovoi matematicheskoi modeli dvigatelya [Identification of the Onboard Mathematical Model of the Engine]. *Sistemy avtomaticheskogo upravleniia aviatsionnymi silovymi ustanovkami. Sbornik nauchnykh trudov*. Moscow, 2020, pp. 61-65.

9. Ostapenko S.V., Iuzhakov A.A. Povyshenie otkazoustoichivosti SAU s pomoshch'iu primeneniia algoritmov iskusstvennogo intellekta [Improving the Fault Tolerance of Automatic Control Systems by Using Artificial Intelligence Algorithms]. *Matematicheskoe modelirovanie. Materialy II Mezhdunarodnoi konferentsii*. Moscow, 2021, pp. 68-70.

10. Ostapenko S.V., Andrievskaia N.V., Iuzhakov A.A. Povyshenie otkazoustoichivosti gazoturbinnnykh dvigatelei za schet ispol'zovaniia vstrai-vaemoi eksperimental'noi modeli [Improving the Fault Tolerance of Gas-Turbine Engines by Using an Embedded Experimental Model]. *Nauchno-tekhnicheskii vestnik Povolzh'ia*, 2023, no. 11, pp. 372-378.

11. Ostapenko S.V., Andrievskaia N.V., Iuzhakov A.A. Primenenie regressionnykh modelei v zadachakh povysheniia otkazoustoichivosti gazoturbinnnykh dvigatelei [Application of Regression Models in Tasks of Increasing the Fault Tolerance of Gas-Turbine Engines]. *Vestnik Povolzhskogo gosudarstvennogo tekhnologicheskogo universiteta. Radiotekhnicheskie i infokommunikatsionnye sistemy*, 2024, no. 1 (61), pp. 70-76.

12. Ezrokhi Iu.A., Kalenskii S.M. Identifikatsiia matematicheskoi modeli aviatsionnogo GTD po rezul'tatam ispytanii [Identification of a Mathematical Model of an Aviation Gas Turbine Engine Based on Test Results]. *Trudy Moskovskogo aviatsionnogo instituta*, 2022, no. 122, pp. 19-38.

13. Andrievskaia N.V. Identifikatsiia nelineinoi modeli s ispol'zovaniem modelei nechetkoi logiki i iskusstvennykh neironnykh setei [Identification of a Nonlinear Model Using Fuzzy Logic Models and Artificial Neural Networks]. *Neirokomp'iutery: razrabotka, primenenie*, 2017, no. 6, pp. 3-8.

14. Andrievskaya N.V., Mubarakzyanov N.R., Bezukladnikov I.I. Identification of parameters of nonlinear model of a hydro-mechanical system. *Proceedings of the 19th International Conference on Soft Computing and Measurements, SCM-2016*, 2016, pp. 145-158.

15. Vasil'ev V.I., Idrisov I.I., Makarov A.S. Neurosetevye tekhnologii proektirovaniia sistem upravleniia aviadvigatelem [Neural Network Technologies for Designing Aircraft Engine Control Systems]. *Innovatsionnye informatsionnye tekhnologii. Trudy rossiisko-nemetskogo seminara*. Ufa, 2009, pp. 72-77.

16. Vasil'ev V.I., Idrisov I.I., Makarov A.S. Proektirovanie perspektivnoi neurosetevoi sistemy upravleniia GTD [Designing a promising neural network control system of a gas turbine engine]. *CSIT'2009. Trudy 11-go Mezhdunarodnogo seminara po komp'iuternym naukam i informatsionnym tekhnologiam*. Krit, Gretsiia, 2009, pp. 13-18.

17. Ershov I.A., Stukach O.V. Ispol'zovanie korrektnogo normirovaniia statisticheskikh dannykh v klasternom analize [Using Correct Normalization of Statistical Data in Cluster Analysis]. *Sovremennye tekhnologii podderzhki priniatiia reshenii v ekonomike. Sbornik trudov vserossiiskoi nauchno-prakticheskoi konferentsii studentov, aspirantov i molodykh uchenykh, Iurga, 19-20 November 2015*. Tomsk: Tomsk Polytechnic University, 2015, pp. 32-34.

18. Vasil'ev V.I., Idrisov I.I., Makarov A.S. Neurosetevye tekhnologii v zadachakh upravleniia i kontrolya aviatsionnykh dvigatelei [Neural network technologies in the problems of control and monitoring of aircraft engines]. *Sistemy upravleniia i informatsionnye tekhnologii*, 2011, no. 1.1 (43), pp. 122-126.

19. Vasil'ev V.I., Idrisov I.I., Karimov I.A., Makarov A.S. Proektirovanie i tekhnicheskaiia realizatsiia intellektual'nykh sistem upravleniia aviatsionnymi gazoturbinnymi dvigateliami [Design and Technical Implementation of Intelligent Control Systems for Aviation Gas-Turbine Engines]. *Intellektual'nye sistemy upravleniia*. Moscow: Mashinostroenie, 2010, pp. 142-153.

20. Deitel P., Deitel Kh. D27 Python: iskusstvennyi intellekt, bol'shie dannye i oblachnye vychisleniia [Python: Artificial Intelligence, Big Data and Cloud Computing]. Saint Petersburg: Piter, 2020, 864 p.

21. Andrew NG Machine learning yearning, available at: <http://www.mlyearning.org/>

22. Weizhong Y. Toward automatic time-series forecasting using neural networks. *IEEE Transaction on neural networks and learning systems*, 2012, vol. 23, no. 7, pp. 1028-1039.

23. Uatt Dzh. et al. Mashinnoe obuchenie: osnovy, algoritmy i praktika primeneniia [Machine Learning: Fundamentals, Algorithms and Practical Applications]. Saint Petersburg: BKhV-Peterburg, 2022, 640 p.

24. Sholle F. Glubokoe obuchenie na Pyton [Deep Learning in Python]. Saint Petersburg: Piter, 2023, 576 p.

25. Rashka S., Mirdzhalili V. Pyton i mashinnoe obuchenie [Python and Machine Learning]. Kiev: Dialektika, 2020, 848 p.

Сведения об авторах

Андриевская Наталья Владимировна (Пермь, Российская Федерация) – кандидат технических наук, доцент, доцент кафедры «Микропроцессорные средства автоматизации» Пермского национального исследовательского политехнического университета (614990, Пермь, Комсомольский пр., 29, e-mail: andrievskai_nv@pstu.ru).

Остапенко Сергей Владимирович (Пермь, Российская Федерация) – генеральный конструктор АО «ОДК-СТАР» (614900, Пермь, ул. Куйбышева, 140А, e-mail: ostap-sv@ao-star.ru).

Южаков Александр Анатольевич (Пермь, Российская Федерация) – доктор технических наук, профессор, заведующий кафедрой «Автоматика и телемеханика» Пермского национального исследовательского политехнического университета (614990, Пермь, Комсомольский пр., 29, e-mail: ux@at.pstu.ru).

About the authors

Natalia V. Andrievskaia (Perm, Russian Federation) – Ph. D. in Technical Sciences, Associate Professor Department of Microprocessor Automation Tools Perm National Research Polytechnic University (614990, Perm, 29, Komsomolsky pr., e-mail: andrievskaia_nv@pstu.ru).

Sergey V. Ostapenko (Perm, Russian Federation) – general designer JSC «ODK-STAR», (614990, Perm, 140A, Kuibisheva str., e-mail: ostap-sv@ao-star.ru).

Aleksandr A. Iuzhakov (Perm, Russian Federation) – Doctor of Technical Sciences, Professor, Head of the Department of Automation and telemechanic Perm National Research Polytechnic University (614990, Perm, 29, Komsomolsky pr., e-mail: uz@at.pstu.ru).

Поступила: 24.10.2025. Одобрена: 01.11.2025. Принята к публикации: 10.12.2025.

Финансирование. Исследование не имело спонсорской поддержки.

Конфликт интересов. Авторы заявляют об отсутствии конфликта интересов по отношению к статье.

Вклад авторов. Авторы сделали равноценный вклад в подготовку статьи.

Просьба ссылаться на эту статью в русскоязычных источниках следующим образом:

Андриевская, Н.В. Применение нейронных сетей в экспериментальных моделях для задачи повышения отказоустойчивости газотурбинных двигателей / Н.В. Андриевская, С.В. Остапенко, А.А. Южаков // Вестник Пермского национального исследовательского политехнического университета. Электротехника, информационные технологии, системы управления. – 2025. – № 56. – С. 148–167. DOI: 10.15593/2224-9397/2025.4.07

Please cite this article in English as:

Andrievskaia N.V., Ostapenko S.V., Iuzhakov A.A. Application of neural networks in experimental models to improve failure resistance of gas turbine engines. *Perm National Research Polytechnic University Bulletin. Electrotechnics, information technologies, control systems*, 2025, no. 56, pp. 148-167. DOI: 10.15593/2224-9397/2025.4.07